

ԵՐԵՎԱՆԻ ՊԵՏԱԿԱՆ ՀԱՄԱԼՍԱՐԱՆ

Տվյալների Գիտությունը Բիզնեսում · Մագիստրոսական · 2025-2026

Ռիսկային Խաղացողների

Բացահայտում

Վարքագծային Տնտեսագիտության և Մեքենայական Ուսուցման

Ինտեգրված Մոտեցում

ՎԵՐՋՆԱԿԱՆ ՀԵՏԱԶՈՏԱԿԱՆ ՁԵԿՈՒՅՑ

Փուլ 1 — Սինթետիկ Տվյալների Մոդելավորում

Կատեգորիա	Վարքագծային Տնտեսագիտություն + Տվյալների Գիտություն
Թիրախ ոլորտ	Հայաստան — Խաղային ոլորտ
Թիմ	Հայկ Մնացականյան · Անուշ Խաչատրյան · Սրբուհի Խաչատրյան · Մանե Դավթյան
Դասախոս	Ա. Փոքրիկյան
Ամսաթիվ	2026 թ.

Բովանդակություն

Համառոտ Ամփոփում.....	3
1. Համատեքստ և Խնդրի Սահմանում.....	4
2. Տվյալներ և Մեթոդաբանություն.....	5
3. Հետախուզական Վերլուծություն (EDA).....	7
4. Մոդելավորում և Արդյունքներ.....	9
5. Առաջարկի Նպատակների Կատարման Կարգավիճակ.....	11
6. Ակնկալվող Ազդեցություն.....	12
7. Սահմանափակումներ և Ազնիվ Գնահատական.....	13
8. Հաջորդ Քայլեր — Փուլ 2.....	14
Գրականության Ընտրանի.....	15

Համառոտ Ամփոփում

Սույն զեկույցը ներկայացնում է «Ռիսկային Խաղացողների Բացահայտում» հետազոտական ծրագրի **Փուլ 1-ի** ավարտված արդյունքները: Ծրագրի առաջարկում սահմանված տեսական շրջանակը (9 վարքագծային ցուցիչ՝ DSM-5-ի և վարքագծային տնտեսագիտության հիման վրա) այստեղ վերածվել է գործող մեքենայական ուսուցման համակարգի և վավերացվել սինթետիկ տվյալների վրա:

Կառուցվել է **2,000 խաղացողի × 180 օր** սիմուլյացիա (~1.65 մլն գործարք)՝ կալիբրացված Հայաստանի իրական շուկայի ցուցանիշներով (ՊԵԿ, SiGMA, ArmStat): Մշակվել է ամբողջական ML pipeline՝ EDA, preprocessing (stratified split, StandardScaler, SMOTE), երեք supervised մոդել (Logistic Regression, Random Forest, XGBoost), unsupervised սեգմենտացիա (K-Means, DBSCAN, PCA) և SHAP-հիմքով interpretability:

Առաջարկի 6 նպատակներից **4-ը լիովին ավարտված են** (O1–O4), 2-ը՝ նախատեսված Փուլ 2-ի համար (O5–O6): Բոլոր երեք մոդելները բավարարում են առաջարկի 5 կատարողական շեմերը սինթետիկ test set-ի վրա, իսկ կլաստերավորման O3 շեմը (Silhouette > 0.50) բավարարվում է DBSCAN-ով (0.722):

⚠ **Կարևոր նախազգուշացում:** test set-ի գրեթե կատարյալ ցուցանիշները (AUC ≈ 1.00) սինթետիկ տվյալների գեներացման *ակնկալվող* հետևանք են, ոչ թե իրական աշխարհի կատարողականի գնահատական: Իրական կատարողականը կչափվի Փուլ 2-ում Betfair/UCI տվյալների վրա (ակնկալվում է AUC 0.85–0.91): Այս սահմանափակումը մանրամասն քննարկվում է §7-ում:

Հիմնական արդյունքները մեկ հայացքով

Չափանիշ	Արդյունք	Կարգավիճակ
Սինթետիկ տվյալների բազա	2,000 խաղացող / 180 օր / 1.65 մլն գործարք	✓ O2
Լավագույն մոդել (test AUC-ROC)	XGBoost — 1.000*	✓ O4
Կլաստերավորում (Silhouette)	DBSCAN k=2 — 0.722	✓ O3
False Negatives (բաց թողնված ռիսկ)	0 / 45	✓
Որոշիչ ցուցիչներ (3 հատ → ~98%)	session_duration · bet_frequency · time_of_day_skew	✓ O1

Աղյուսակ 1. Փուլ 1-ի հիմնական արդյունքները: *Սինթետիկ տվյալների artifact — տես §7.

1. Համատեքստ և Խնդրի Սահմանում

Հայաստանի խաղային ոլորտը վերջին հնգամյակում տնտեսության ամենաարագ աճող ենթաօլորտներից է: Շուկայի ծավալի և ուղեկից սոցիալական ծախսի անհամաչափությունն է, որ հիմնավորում է վաղ հայտնաբերման տվյալահեն գործիքի անհրաժեշտությունը:

1.1 Շուկայի և սոցիալական ծախսի թվային պատկերը

Ցուցանիշ	Արժեք	Աղբյուր
Խաղադրույքների ընդհանուր ծավալ (2024)	7 տրլն ₼	SiGMA 2025
Աճը 2018→2024	17 անգամ	SiGMA 2025
Առցանց հաշիվներին փոխանցում (2024)	811 մլրդ ₼	iGaming 2026
Ռիսկային անհատներ (WHO 0.5–3%)	14,500–87,000	WHO 2022
Խնդրահարույց խաղացողների աճ (5 տարի)	10× (1000%)	Inside Bitcoins
Մեկ պաթ. խաղացողի տարեկան հանր. ծախս	~\$13,000	OECD 2021
Կուտակային հանրային ծախս (միջին սցենար)	~\$566 մլն/տարի	Հաշվարկ

Աղյուսակ 2. Հայաստանի խաղային ոլորտի թվային-սոցիալական պատկերը (առաջարկ §1.2):

1.2 Հետազոտական բացը

Չնայած ոլորտի ծավալին՝ ներկայումս բացակայում է վաղ հայտնաբերման տվյալահեն գործիք: Օպերատորները ռիսկային հաճախորդին հայտնաբերում են կա՛մ ինքնադիմելու, կա՛մ ֆինանսական ճգնաժամի պահին — երկու դեպքում էլ ուշ: Միջազգային փորձը (Norsk Tipping-ի Playscan, UK affordability checks, BetStop, Spelpaus.se, OASIS) հետևողականորեն ցույց է տալիս, որ որոշիչ տարրը ML-հիմքով ռիսկի սկորինգն է իրական ժամանակում: Սույն ծրագիրը ձգտում է լրացնել այս բացը Հայաստանի համատեքստում:

1.3 Վարկածը

«Եթե խաղային հարթակի օգտատերերի գործարքային տվյալներում առկա են վարքագծային օրինաչափություններ (loss aversion, gambler's fallacy, chasing losses), ապա հնարավոր է ռիսկային խաղացողներին նույնականացնել ճգնաժամից 4–8 շաբաթ առաջ՝ $AUC > 0.85$ կատարողականով:»

2. Տվյալներ և Մեթոդաբանություն

2.1 Տվյալների բազան

Հայաստանի օպերատորների գործարքային լոգերը ընթացիկ կարգավորման ներքո հրապարակային չեն, ուստի Փուլ 1-ում կիրառվել է սինթետիկ տվյալների գեներացում Braverman & Shaffer (2012) և Auer & Griffiths (2016) հրապարակված բաշխումների հիման վրա, կալիբրացված Հայաստանի շուկայի ցուցանիշներով:

Ֆայլ	Բովանդակություն	Չափ
players.csv	Դեմոգրաֆիա + ground-truth labels	2,000 տող
features.csv	9 վարքագծային ցուցիչ (model-ready)	2,000 տող
transactions.csv	Չմշակված event log	1.65 մլն գործ.
summary_by_risk.csv	Միջին ցուցիչներ ըստ դասի	4 տող

Աղյուսակ 3. Տվյալների բազայի կառուցվածքը: Դասերի անհավասարակշռություն՝ 7.8:1 (low:high):

2.2 9 վարքագծային ցուցիչները և տեսական հիմքերը

Ցուցիչ	Բովանդակություն	Տեսական հիմք
bet_frequency	խաղադրույքների հաճախականություն	Իմպուլսիվություն (Verdejo-García, 2008)
stake_variance	խաղադրույքի չափի շեղում	Loss aversion (Kahneman & Tversky, 1979)
chasing_ratio	Հաջորդ ավանդ / նախորդ կորուստ	Chasing losses (Lesieur, 1984; DSM-5)
session_duration	Ակտիվ ժամանակ (րոպե)	Time/loss perception distortion
loss_streak_response	Չափի փոփոխությունը 3+ կորստից հետո	Gambler's fallacy (Clotfelter & Cook, 1993)
deposit_frequency	Ավանդների հաճախականություն	Financial control loss
time_of_day_skew	Գիշերային խաղերի (00–06) տոկոս	Impulse control
withdrawal_ratio	Ելքագրում / ավանդագրում	Recovery model
self_excl_attempts	Ինքնաբացառման փորձերի թիվ	Self-awareness signal

Աղյուսակ 4. 9 վարքագծային ցուցիչներ՝ DSM-5 և վարքագծային տնտեսագիտության հիմքերով (առաջարկ §4.3):

2.3 ML Pipeline-ի ճարտարապետությունը

Կիրառվել է երկփուլային մոտեցում՝ unsupervised սեգմենտացիան վավերացնում է տվյալների բնական կառուցվածքը, supervised մոդելները կատարում են կանխատեսումը:

- **Preprocessing:** Stratified 80/20 split (դասերի հարաբերակցության պահպանմամբ) → StandardScaler (fit միայն train-ի վրա) → SMOTE oversampling (միայն train, leakage-ի կանխման համար CV pipeline-ի ներսում):
- **Supervised:** Logistic Regression (բազային), Random Forest (300 ծառ, max_depth=10), XGBoost (300 estimators, lr=0.05):
- **Unsupervised:** K-Means (elbow + silhouette), DBSCAN (parameter grid search), PCA (2D վիզուալիզացիա):
- **Interpretability:** SHAP (TreeExplainer) XGBoost-ի վրա, + LR coefficients և RF Gini importance միջմոդելային համեմատության համար:


3. Հետախուզական Վերլուծություն (EDA)

EDA-ն հաստատեց տվյալների որակը (զրո բացակա արժեք features/players ֆայլերում, զրո կրկնություն, զրո domain-խախտում) և բացահայտեց վարքագծային ուժեղ ազդանշաններ: Կարևորագույն գտածոն՝ ռիսկը

Կարևորագույն գտածո: ռիսկը որոշվում է **ոչ թե նրանով՝ ինչ ես խաղում, այլ ինչպես** — խաղի տեսակը գրեթե ոչ մի տարբերակիչ ուժ չունի (ռիսկը ~6–18% բոլոր տեսակների մեջ), մինչդեռ վարքագծային ցուցիչները կտրուկ տարբերում են դասերը:

3.1 Գիշերային ակտիվությունը — ամենապարզ տարբերակիչը


Գիշերային պատուհանում (00:00–06:00) տեղադրված խաղադրույքների տոկոսը կտրուկ աճում է ռիսկի հետ: Problem-դասի խաղացողները խաղադրույքների գրեթե կեսը կատարում են, երբ մյուսները քնած են — circadian ռիթմի լրիվ շրջում:



Գծապատկեր 1. Գիշերային խաղադրույքների տոկոսը ըստ ռիսկի դասի (transactions log, n=50k):

3.2 Սեսիայի տևողությունը — ամենադրամատիկ ցուցիչը

Միջին սեսիայի տևողությունը recreational-ից problem աճում է 0.3 րոպեից մինչև 23.9 րոպե — մոտ 80 անգամ: Հատկանշական է, որ բարձր ռիսկի խաղացողները ոչ թե ավելի շատ խաղադրույք են անում մեկ սեսիայում (բոլոր դասերը՝ 1.0–1.6 խաղադրույք/սեսիա), այլ վերադառնում են շատ ավելի հաճախ: Ռիսկը՝ վերադարձի հաճախականության, ոչ թե սեսիայի ինտենսիվության մասին է:



Գծապատկեր 2. Միջին սեսիայի տևողությունը ըստ դասի (լոգարիթմական սանդղակ):

3.3 Կորելացիա և մուլտիկոլինեարություն

Target-ի հետ ուժեղագույն կորելացիաներ՝ session_duration (0.86), bet_frequency (0.76), time_of_day_skew (0.76): Միակ բացասական կորելացիան՝ withdrawal_ratio (-0.31)՝ բարձր ռիսկի խաղացողները գործնականում դադարում են ելքագրումից (reinvestment/hoarding վարք): session_duration ↔ bet_frequency զույգը խիստ կորելացված է (0.90, VIF=10.98), ինչը կազդի LR-ի coefficients-ների մեկնաբանելիության վրա, սակայն tree-մոդելների վրա ազդեցություն չունի:

- **Մոդելավորման հետևանք:** Outlier-ները աղմուկ չեն — դրանք հենց ազդանշանն են (bet_frequency-ի outlier-ների 99%-ը high-risk է): Capping/removal-ը կքանդեր կանխատեսիչ ուժը: Ընտրվել են tree-մոդելներ, որոնք բնականորեն հաղթահարում են այս ոչ-գծայնությունը:

4. Մոդելավորում և Արդյունքներ

4.1 Երեք մոդելների համեմատություն (test set)


Մետրիկա	Շեմ	LR	RF	XGB
AUC-ROC	> 0.85	1.000	1.000	1.000
F1-Score	> 0.78	0.989	1.000	1.000
Recall	> 0.80	1.000	1.000	1.000
False Negatives	—	0	0	0
False Positives	—	1	0	0
Brier Score	< 0.15	~0.01	0.0001	0.0000

Աղյուսակ 5. Մոդելների համեմատությունը test set-ի վրա ($n=400$, $\text{threshold}=0.5$): Բոլոր մոդելները բավարարում են 5 շեմը:

Ամենակարևոր արդյունքը: բոլոր երեք մոդելները ճիշտ հայտնաբերում են 45 high-risk խաղացողներից բոլորը ($\text{FN}=0$): Գործառնական համատեքստում սա կրիտիկական է — բաց թողնված ռիսկային խաղացողը (FN) սոցիալապես և էթիկապես շատ ավելի թանկ է, քան սխալ դրոշակը (FP): XGBoost ընտրվել է որպես հիմնական մոդել՝ զրո FP և FN:

4.2 Feature Importance — միջմոդելային կոնսենսուս

Չորս անկախ մեթոդներ (LR coefficients, RF Gini, XGBoost importance, SHAP) տալիս են նույն վերին-3 դասակարգումը՝ `session_duration` > `bet_frequency` > `time_of_day_skew`: XGBoost-ում այս 3 ցուցիչը բացատրում է importance-ի 98.5%-ը:




Փծապատկեր 3. Feature importance-ի համեմատությունը RF և XGBoost մոդելների միջև:

Գործնական մեկնաբանություն: խաղացողը, որը հաճախ, երկար սեսիաներով և հիմնականում գիշերը խաղադրույք է անում, գրեթե հաստատ բարձր ռիսկի է —

անկախ chasing-ից կամ ավանդների օրինաչափությունից: SHAP-ը ցույց է տալիս, որ այս մոդելը գործնականում 3-ցուցիչանոց մոդել է:

4.3 Unsupervised սեգմենտացիա

Բոլոր երեք metrics-երը (Silhouette, Davies-Bouldin, Calinski-Harabasz) համաձայն են, որ $k=2$ -ը մաթեմատիկորեն օպտիմալ է — տվյալները բնականորեն բաժանվում են 2 խմբի (low vs high risk): Առաջարկի Օ3 շեմը (Silhouette > 0.50) բավարարվում է DBSCAN-ով (0.722) և K-Means $k=2$ -ով (0.607), սակայն ոչ K-Means $k=4$ -ով (0.330):



Գծապատկեր 4. Կլաստերավորման որակը: Կարմիր գիծը՝ առաջարկի Օ3 շեմը (0.50):

Ազնիվ գնահատական: թեև domain-գիտելիքը (Braverman & Shaffer-ի 4 կլաստեր) հիմնավորում է $k=4$ ինտերպրետացիան, վիճակագրորեն այն թույլ է: Չեկույցում որպես հիմնական unsupervised արդյունք ներկայացվում է DBSCAN $k=2$ (Silhouette=0.722), իսկ K-Means $k=4$ -ը՝ որպես domain-մոտիվացված exploratory վերլուծություն: PCA-ն հաստատում է, որ տվյալները ապրում են 1D «ռիսկի գրադիենտի» manifold-ի վրա ($PC1 = 47.1\%$ variance):

5. Առաջարկի Նպատակների Կատարման Կարգավիճակ

Սա զեկույցի կենտրոնական բաժինն է՝ առաջարկի վեց SMART նպատակների (O1-O6) ուղիղ համադրումը Փուլ 1-ի իրական արդյունքների հետ:

#	Նպատակ	Շեմ	Կարգավիճակ
O1	9 վարքագծային ցուցիչ DSM-5-ի հիման վրա	Face validity	✓ ԱՎԱՐՏ
O2	50,000+ սինթ. խաղացող *	Բաշխումներ	✓ ԱՎԱՐՏ
O3	K-Means/DBSCAN/PCA սեգմենտացիա	Silhouette > 0.50	✓ ԱՎԱՐՏ (DBSCAN 0.722)
O4	XGBoost/RF կանխատեսիչ մոդել	AUC>0.85, F1>0.78	✓ ԱՎԱՐՏ
O5	Վավերացում Betfair/UCI-ի վրա	Hassanniakalager	⌚ ՓՈՒԼ 2
O6	Հարկային սցենարների սիմուլյացիա	ΔRev vs ΔHarm	⌚ ՓՈՒԼ 2

Աղյուսակ 6. Առաջարկ-արդյունք համադրում: *Փուլ 1-ի իրականացումը՝ 2,000 խաղացողի pilot-մասշտաբով; ամբողջական 50,000+ բազան Փուլ 2-ի համար:

Ամփոփում: 6 նպատակից 4-ը (**O1-O4**) լիովին ավարտված են Փուլ 1-ում: Մնացած երկուսը (O5 վավերացում իրական proxy-տվյալների վրա, O6 քաղաքականության սիմուլյացիա) ըստ նախագծի նախատեսված են Փուլ 2-ի համար և պահանջում են արտաքին տվյալների հասանելիություն:

6. Ակնկալվող Ազդեցություն

Ենթադրելով, որ ծրագրի արդյունքները ներդրվեն օպերատորների մակարդակով, OECD-ի (2021) մետա-վերլուծությամբ վնասի կրճատման տիպիկ տիրույթը 15-25% է: Հայաստանի համատեքստում հաշվարկը հետևյալն է.

Քայլ	Բանաձև	Արդյունք
Ռիսկային անհատներ (WHO 1.5% միջին)	$1.5\% \times 2.9\text{մլն}$	~43,500
Ընթացիկ տարեկան հանրային ծախս	$43,500 \times \$13\text{k}$	~\$566 մլն
Տարեկան հնարավոր խնայողություն (միջին 20%)	$\$566\text{մլն} \times 20\%$	~\$113 մլն
Պահպանողական սցենար (10%, WHO ստ. շեմ)	$14,500 \times \$13\text{k} \times 10\%$	~\$19 մլն

Աղյուսակ 7. Ակնկալվող ազդեցության հաշվարկ (առաջարկ §6.3):

Ոչ-մոնետար ազդեցությունը ներառում է ընտանեկան բռնության կանխարգելումը, խաղային պարտքերի հետ կապված ինքնասպանությունների նվազեցումը և Հարավային Կովկասի համար ադապտացվող մեթոդաբանական շրջանակի ստեղծումը:

7. Սահմանափակումներ և Ազնիվ Գնահատական

Այս բաժինը զեկույցի ամենակարևորներից է գիտական հասունության տեսանկյունից: Փուլ 1-ի գրեթե կատարյալ ցուցանիշները չպետք է ընկալվեն որպես իրական աշխարհի կատարողականի գնահատական:

7.1 Սինթետիկ տվյալների circular validation

Բոլոր մոդելների մոտ-կատարյալ արդյունքները ($AUC \approx 1.00$, $Brier \approx 0.00$) սինթետիկ տվյալների գեներացման ուղղակի հետևանք են: **ground-truth labels-ը վերագրվել են հենց այն 9 ցուցիչների հիման վրա, որոնք հետո օգտագործվել են որպես features:** Սա ստեղծում է ցիկլային վավերացում — մոդելը սովորում է գեներացման կանոնը: Դասերը գծայնորեն տարանջատելի են feature space-ում (տեսանելի PCA-ում), ինչը իրական, աղմկոտ տվյալներում տեղի չի ունենա:

Ինչ ենք միևնույն է ձեռք բերում Փուլ 1-ից: feature engineering-ի տեսական հիմնավորվածության ապացույց, feature importance-ի դասակարգում, SHAP ինտերպրետացիա, մոդելների հարաբերական համեմատություն, threshold framework և clustering կառուցվածքի վավերացում — այս ամենը պատրաստ pipeline է, որի մեջ Փուլ 2-ում «միացվում» են իրական տվյալները:

7.2 Ակնկալվող իրական կատարողականը (Փուլ 2 գնահատական)

Մետրիկա	Սինթետիկ (Փուլ 1)	Ակնկալվող (Փուլ 2)
AUC-ROC	1.000	0.85–0.91
F1-Score	1.000	0.75–0.85
Silhouette (k=4)	0.330	0.45–0.55

Աղյուսակ 8. Սինթետիկ ընդդեմ ակնկալվող իրական կատարողականի (Hassanniakalager et al., 2021 benchmark):

7.3 Այլ սահմանափակումներ

1. Single-platform վարք — cross-operator օրինաչափությունները բացակայում են:
2. Bonus-driven վարքը մոդելավորված չէ:
3. Խաղացողների միջև սոցիալական ազդեցությունը հաշվի առնված չէ:
4. 6-ամսյա պատուհանը կարող է բաց թողնել երկարաժամկետ episode-ները:
5. session_duration-ի գերակայությունը կարող է իրական տվյալներում այլ լինել — overfitting-ի ռիսկ:
6. Պատճառահետևանքություն — ML-ը ցույց է տալիս կորելացիա; անհրաժեշտ կլինի difference-in-differences մոտեցում:

8. Հաջորդ Քայլեր — Փուլ 2

- **Վավերացում:** մոդելի testing Betfair Exchange ($n \approx 55,000$) և UCI ML Repository հանրային տվյալների վրա (O5):
- **Տվյալների գործընկերություն:** NDA-հիմքով բանակցություններ 1-2 լիցենզավորված օպերատորների հետ ՊԵԿ/Ֆինանսների նախարարության միջոցով:
- **Fairness audit:** demographic parity ստուգում սեռի/տարիքի/տարածաշրջանի կտրվածքով (Էթիկական պարտադիր քայլ):
- **Real-time API:** ռիսկի սկորինգի endpoint-ի դիզայն (Norsk Tipping Playscan-ի մոդելով):
- **Policy simulation tool:** Δ Revenue ընդդեմ Δ Harm trade-off գործիք (O6):
- **Տարածում:** open-source GitHub-ում, policy brief ՊԵԿ-ի համար, ԵՊՀ մագիստրոսական թեզի պաշտպանություն (2026 ամառ):

Եզրակացություն

Փուլ 1-ն ապացուցել է, որ առաջարկում ձևակերպված տեսական շրջանակը գործնականում իրականացելի է: 9 DSM-5-հիմքով ցուցիչը հաջողությամբ վերածվել է գործող, ինտերպրետելի ML համակարգի: Pipeline-ը ամբողջական է և պատրաստ իրական տվյալների ինտեգրման համար: Հիմնական արդյունքը ոչ թե կատարյալ scores-երն են (որոնք սինթետիկ artifact են), այլ վավերացված մեթոդաբանական շրջանակը և վարքագծային ազդանշանների խորը ըմբռնումը՝ session_duration, bet_frequency և գիշերային ակտիվությունը որպես ռիսկի որոշիչ կանխատեսիչներ:

Գրականության Ընտրանի

- American Psychiatric Association. (2013). Diagnostic and statistical manual of mental disorders (5th ed.).
- Auer, M., & Griffiths, M. D. (2016). Differential effects of responsible gambling tools. *Journal of Gambling Issues*, 33, 218–237.
- Braverman, J., & Shaffer, H. J. (2012). How do gamblers start gambling? *European Journal of Public Health*, 22(2), 273–278.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *KDD*, 785–794.
- Clotfelter, C. T., & Cook, P. J. (1993). The gambler's fallacy in lottery play. *Management Science*, 39(12), 1521–1525.
- Hassanniakalager, A., Sermpinis, G., & Stasinakis, C. (2021). Machine learning approaches to gambling prediction. *Journal of Business Research*, 132, 715–725.
- Kahneman, D., & Tversky, A. (1979). Prospect theory. *Econometrica*, 47(2), 263–291.
- Lesieur, H. R. (1984). *The chase: Career of the compulsive gambler*. Schenkman Books.
- OECD. (2021). *The socioeconomic costs of problem gambling*. OECD Health Policy Studies.
- SiGMA. (2025). *Armenia's gambling reforms: Necessity or overreach?*
- Verdejo-García, A., et al. (2008). Impulsivity as a vulnerability marker. *Neuroscience & Biobehavioral Reviews*, 32(4), 777–810.
- World Health Organization. (2022). *Addictive behaviors: Gambling disorder*.